优化理论——拉格朗日乘子法和KKT条件

```
星空爱好者
   优化理论.机器学习
₩ 2021 科学自立季 >
```

导语

36 人赞同了该文章

拉格朗日乘子法和KKT条件应用于求解带约束条件的优化模型 拉格朗日乘子法的意义:通过引入新的自由变量,将等式不等式的约束条件转化为无约束或约束 简单的优化问题进行求解。

KKT条件的意义:满足KKT条件的K-T点是模型最优解的必要条件,对于凸优化而言,K-T点是最 优解的充要条件。通常直接求解优化模型往往比较困难,转而求解KKT条件方程组的解,再去验 证方程解是否为模型的最优解,从而大幅度提升了优化模型的求解效率。

等式约束模型

对于等式约束**原模型**:

 $min \ f(x)$ s.t. g(x) = c $x \in R$

引入自由变量 λ ,构建拉格朗日函数 $L(x,\lambda)=f(x)+\lambda(g(x)-c)$,接下来证明原模型等价 于无约束优化模型

 $min \; L(x,\lambda)$ $s.\,t.\,\,x,\lambda\in R$

等价证明1

拉格朗日函数对偶形式为

 $\max_{\lambda} heta_d(\lambda) = \max_{\lambda} \min_{x} f(x) + \lambda (g(x) - c)$

则 $\max_{\lambda} L(x^*, \lambda)$,根据约束分为两种情况 $\left\{egin{array}{ll} f(x^*), & g(x^*) = c \ f(x^*) + \lambda(g(x^*) - c), & g(x^*)
eq c \end{array}
ight.$

假设 $x^* = rg \min_x f(x) + \lambda(g(x) - c)$

 $\pmb{\lambda}$ 是自由变量, $g(x^*) \neq c$ 时为线性函数,可以取到无穷大或者无穷小, $\max_{\pmb{\lambda}} L(x^*, \pmb{\lambda})$ 只能

等价证明2 模型存在最优解,则目标函数 f(x) 与约束函数 g(x)=c 必然相交。凸函数最优点只有一个,


所以只有约束条件与目标函数等高线的切点才是优化模型的最优解。切点处,目标函数梯度与约

束函数梯度平行,公式化为 $f'(x) = -\lambda g'(x)$

从而验证了拉格朗日函数 $L(x,\lambda)=f(x)+\lambda(g(x)-c)$ 的正确性。

$(0.5x - 0.5)^2$

取 $g(x^*)=c$ 的第一种情况。因此 $min\ L(x,\lambda)$ 等价于原模型。



其在各个自由变量处的导数为0。因此,等式约束优化模型的KKT条件为

 $\left\{ egin{array}{l} rac{\partial L}{\partial x} = f'(x) + \lambda g'(x) = 0 \ rac{\partial L}{\partial \lambda} = g(x) - c = 0 \end{array}
ight.$

这里的拉格朗日函数 $L(x,\lambda)=f(x)+\lambda(g(x)-c)$ 已经成为了无约束函数,最优解自然满足

$min \ f(x)$ $s.\,t.\;h(x)\leq t$

不等式约束模型

$x \in R$ 这里引入一个自由变量 s 使得不等式约束问题转化成等式约束问题如下

对于不等式约束**原模型**:

 $min \ f(x)$ $s.\,t.\,h(x)+s^2=t$


为

 $x,s \in R$ 对应的拉格朗日函数 $L(x,\mu,s)=f(x)+\mu(h(x)+s^2-t)$,等式约束优化模型的KKT条件

首先由于KKT条件要求
$$f'(x)=-\mu h'(x)$$
。对于目标函数,约束起作用意味着越是远离约束边界的解空间使得目标函数值越大, t 已经属于 $h(x)$ 最大取值,随着可行解远离约束边界 $h(x)$ 递减。这两个函数的梯度是相反的,因此 $f'(x)$ 与 $h'(x)$ 异号,所以拉格朗日乘子 $\mu\geq 0$ 。此

 $egin{cases} rac{\partial L}{\partial x} = f'(x) + \mu h'(x) = 0 \ rac{\partial L}{\partial \mu} = h(x) + s^2 - t = 0 \ rac{\partial L}{\partial s} = 2 \mu s = 0 \end{cases}$

处解释可能较为抽象,以下图为例更容易理解。



第二种情况: $\mu \geq 0, s = 0$, $h(x^*) = t$ 最优解在不等式约束的边界上,此时不等式约束转化为等式约束。 基于对 $\mu s=0$ 的讨论,等价于 $\mu(h(x)-t)=0$

最优解 x^* 在不等式内部,此时不等式约束无效,即拿掉此不等式约束对最优解无影响

 $\int f'(x) + \mu h'(x) = 0$ $\mu(h(x)-t)=0 \ h(x)-t\leq 0$

等式不等式约束模型

对于等式不等式联合约束的优化模型

第一种情况: $\mu = 0, s
eq 0$, $h(x^*) < t$

综上,不等式模型的KKT条件总结如下:

$h(x) \leq t$ $x \in R$

 $min \ f(x)$

 $s.\,t.\,g(x)=c$

此处不再赘述,给出拉格朗日函数 $L(x,\lambda,\mu)=f(x)+\lambda(g(x)-c)+\mu(h(x)-t)$,KKT 条件为

 $\int f'(x) + \lambda g'(x) + \mu h'(x) = 0$

 $\mu(h(x)-t)=0$ 编辑于 2022-05-07 18:40

g(x) = c

 $h(x) \leq t$

凸优化 不等式 拉格朗日乘子

南征北战

写下你的评论...

6条评论



请问文章中生成函数曲线的软件是什么软件?

我觉得有问题。就光看等式优化那里。你说"原模型等价于无约束优化模型"。什么叫等价, 就是原模型和无约束模型的最优值点是相等的(这样我们求解了无约束模型的最优值点,相 当于求解了原模型的最优值点)。但我觉得原模型和拉格朗日函数对应的无约束优化模型是 不等价的。就举个例子,原模型是f(x1,x2)=x1^2+x2^2, g(x)=x1+x2-1=0。最小值是二分之 1, 当x1=x2=二分之一的时候取到。无约束优化模型则没有最小值。所以这两者不等价。当 然,无约束模型的极值点确实是和原模型的极值点是同一个,但最值点不是。现在你用的是 min的记号,而且也没做特殊说明,所以我觉得有问题。 **赞** 04-26 星空爱好者「作者」 这里用到了点对偶思想,即,先极小化x,再极大化乘子,所以不会是你说的情况,这 两天我补充下 **赞** 05-05

文章被以下专栏收录 现代优化理论

推荐阅读

现代优化理论

皮乾东


凸优化有广泛的应用,不过本篇介 绍的凸优化内容只是为了之后的 SVM做铺垫。毛主席说过: " 调查就像十月怀胎,解决问题就像 一朝分娩。调查就是解决问题。... NLP小学生

凸优化、拉格朗日乘子法和

KKT条件



发表于菊子皮的成...



马轶荀

拉格朗日



默认 最新

赞

赞

● 赞